

Введение

С помощью различных моделей машинного обучения можно спрогнозировать эффективность соединений и подобрать наиболее подходящие сочетания параметров для разработки лекарственных средств.

Целью работы является построение прогнозных моделей для оценки эффективности химических соединений против вирусов гриппа.

Описание данных:

Данные о 1000 химических соединений с указанием их эффективности против вируса гриппа. Параметры, характеризующие эффективность, обозначаются как IC50, CC50 и SI – целевые показатели. Всего 213 признаков.

IC50(Half Maximal Inhibitory Concentration) - концентрация вещества, при которой активность вируса подавляется на 50% (высокий показатель означает, что нужно много веществ для подавления вируса, низкий - вещество эффективно уже при малой концентрации).

CC50(50% Cytotoxic Concentration) - концентрация вещества, при которой погибает 50% клеток (высокий показатель означает, что вещество менее токсично, низкий - токсично даже в малом объеме).

SI(Selectivity Index) - индекс селективности препарата (CC50/IC50) (чем выше, тем лучше).

Исследовательский анализ данных (EDA)

В данных были обнаружены пропуски (36), однако все они содержались всего в трех строках, поэтому эти строки удалены.

Также построены boxplot и гистограммы целевых переменных. Наблюдается сильная правосторонняя асимметрия, присутствуют выбросы. Для стабилизации дисперсии и уменьшения влияния экстремальных значений к целевым переменным применено логарифмирование.

Проведен корреляционный анализ. Для всех трех целевых переменных корреляции небольшие, не превышают 0.3. Есть пересечение признаков: fr_NH2, Kappa3, VSA_EState4, NumAliphaticHeterocycles, NumSaturatedHeterocycles и др.. Выделены топ-20 признаков для трех целевых переменных (около 50). После избавления от мультиколлинеарности осталось 30.

Регрессия для CC50

Рассмотренные модели: LinearRegression, RandomForestRegressor, CatBoostRegressor, SVR, XGBRegressor.

Для подбора гиперпараметров был применен RandomizedSearchCV, метрика – negMSE.

Лучшая модель и её параметры: {'scaler': 'passthrough', 'models__n_estimators': 300, 'models__min_samples_split': 10, 'models__min_samples_leaf': 1, 'models__max_depth': None, 'models': RandomForestRegressor(random_state=42)}

Метрики на тестовой выборке:

в логарифмической шкале: rmse – 0.56, mae – 0.39, r2 – 0.37

в исходной шкале: rmse – 579.84, mae – 329.56, r2 – 0.29.

В отличие от предыдущего случая победил RandomForestRegressor, из этого следует, что структура зависимости CC50 от признаков отличается от IC50. Зависимость лучше описывается бэггингом, а не последовательным бустингом. SVR же оказался очень нестабильным, у него очень большой разброс. Линейная регрессия показала худшее качество.

Регрессия для SI

Рассмотренные модели: LinearRegression, RandomForestRegressor, CatBoostRegressor, SVR, XGBRegressor.

Для подбора гиперпараметров был применен RandomizedSearchCV, метрика – negMSE.

Лучшая модель и её параметры: {'scaler': 'passthrough', 'models__learning_rate': 0.01, 'models__iterations': 1000, 'models__depth': 5, 'models': CatBoostRegressor(loss_function='RMSE', random_state=42, verbose=0)}

Метрики на тестовой выборке:

в логарифмической шкале: rmse – 0.72, mae – 0.53, r2 – 0.24

в исходной шкале: rmse – 925.44, mae – 623.41, r2 – -0.82.

В исходной шкале модель показала отрицательный r2, то есть хуже простого прогноза средним. Это говорит о том, что точное количественное предсказание SI в натуральных единицах затруднено, поэтому для задач отбора соединений нужно использовать классификационные модели. В качестве рекомендаций, также можно использовать двухэтапное прогнозирование – сначала получить значения CC50, IC50, потом вычислить SI.

Задачи классификации

Классификация: превышает ли значение IC50 медианное значение выборки

Рассмотренные модели: LogisticRegression, RandomForestClassifier, CatBoostClassifier, KNeighborsClassifier.

Для подбора гиперпараметров был применен RandomizedSearchCV, метрика – roc-auc.

Лучшая модель и её параметры: {'scaler': 'passthrough', 'models__learning_rate': 0.01, 'models__iterations': 200, 'models__depth': 15, 'models': CatBoostClassifier(random_state=42, verbose=0)}

Метрики на тестовой выборке:

accuracy – 0.71

f1 – 0.7

roc_auc – 0.8

Модель хорошо разделяет соединения, может использоваться для первичного скрининга.

Классификация: превышает ли значение CC50 медианное значение выборки

Рассмотренные модели: LogisticRegression, RandomForestClassifier, CatBoostClassifier, KNeighborsClassifier.

Для подбора гиперпараметров был применен RandomizedSearchCV, метрика – roc-auc.

Лучшая модель и её параметры: {'scaler': 'passthrough', 'models__learning_rate': 0.01, 'models__iterations': 1000, 'models__depth': 5, 'models': CatBoostClassifier(random_state=42, verbose=0)}.

Метрики на тестовой выборке:

accuracy – 0.76

f1 – 0.79

roc_auc – 0.85

Данная модель показала лучшую точность среди всех классификаций, её можно использовать для разделения выявляющих токсичных соединений.

Классификация: превышает ли значение SI медианное значение выборки

Рассмотренные модели: LogisticRegression, RandomForestClassifier, CatBoostClassifier, KNeighborsClassifier.

Для подбора гиперпараметров был применен RandomizedSearchCV, метрика – roc-auc.

Лучшая модель и её параметры: {'scaler': 'passthrough', 'models__n_estimators': 150, 'models__min_samples_split': 10, 'models__min_samples_leaf': 1, 'models__max_depth': 40, 'models': RandomForestClassifier(random_state=42)}.

Метрики на тестовой выборке:

accuracy – 0.66

f1 – 0.64

roc_auc – 0.72

Качество получилось хуже, чем у IC50 и CC50, но это закономерно. SI - отношение двух величин, каждая из них при этом вносит неопределенность, следовательно предсказать её сложнее. Полученную модель лучше использовать, как дополнительный фильтр (не как единственный критерий).

Классификация: превышает ли значение SI значение 8

Рассмотренные модели: LogisticRegression, RandomForestClassifier, CatBoostClassifier, KNeighborsClassifier.

Для подбора гиперпараметров был применен RandomizedSearchCV, метрика – roc-auc.

Лучшая модель и её параметры: {'scaler': 'passthrough', 'models__n_estimators': 300, 'models__min_samples_split': 5, 'models__min_samples_leaf': 5, 'models__max_depth': 30, 'models': RandomForestClassifier(class_weight='balanced', random_state=42)}.

Метрики на тестовой выборке:

accuracy – 0.7

f1 – 0.59

roc_auc – 0.73

В данной задаче, в отличие от предыдущих классы не сбалансированы, поэтому были использованы class_weight='balanced'. На тестовой выборке f1 = 0.59 - минорный класс сложнее уловить. Данную модель можно применить, как фильтр для выделения соединений с высокой селективностью. Но для окончательного решения, ее лучше комбинировать с другими источниками информации.

Сводная таблица

Задание	Лучшая модель	Метрика	Значение метрики
Регрессия для IC50	CatBoostRegressor	R^2 (log)	0.54
Регрессия для CC50	RandomForestRegressor	R^2 (log)	0.37
Регрессия для SI	CatBoostRegressor	R^2 (log)	0.24
Классификация: IC50 > медиана	CatBoostClassifier	ROC-AUC	0.8
Классификация: CC50 > медиана	CatBoostClassifier	ROC-AUC	0.85
Классификация: SI > медиана	RandomForestClassifier	ROC-AUC	0.72
Классификация: SI > 8	RandomForestClassifier	ROC-AUC	0.73

Вывод

CatBoost и случайный лес показали лучшие результаты как в регрессии, так и в классификации. Это не случайно, так как они способны моделировать нелинейные зависимости.

На прямую SI спрогнозировать сложно, целесообразнее сначала получить значения для IC50 и CC50 по отдельности, а потом уже вычислить SI. По результатам анализа моделей для отбора соединений лучше использовать классификационные модели с высоким ROC-AUC (IC50, CC50), SI > 8 – как дополнительный инструмент.